

TrafficVision-Transformer: Tái hiện có điều chỉnh kiến trúc Spatio-Temporal Transformer nhẹ cho phát hiện bất thường giao thông trong video từ thiết bị bay không người lái

Vũ Hoàng Diệu Linh, Đặng Quang Minh, Lê Hồng Phương Chi
Viện Trí tuệ nhân tạo
Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội
144 Xuân Thủy, Cầu Giấy, Hà Nội, Việt Nam
{24022387, 24022397, 24022270}@vnu.edu.vn

Tóm tắt—Phát hiện bất thường giao thông trong video quay từ thiết bị bay không người lái là một bài toán khó do camera chuyển động, phương tiện có kích thước nhỏ, mật độ giao thông thay đổi liên tục và dữ liệu bất thường chỉ chiếm tỷ lệ rất nhỏ. Các kiến trúc Video Transformer có khả năng khai thác quan hệ không gian - thời gian tốt, nhưng chi phí huấn luyện lớn khiến việc triển khai trong môi trường tính toán hạn chế trở nên khó khăn. Bài báo này trình bày TrafficVision-Transformer, một nghiên cứu tái hiện có điều chỉnh từ hướng Spatio-Temporal Transformer cho phát hiện bất thường giao thông theo chiến lược học không giám sát. Thay vì tuyên bố một mô hình quy mô lớn mới, nhóm tập trung vào câu hỏi thực tiễn hơn: làm thế nào giữ được ý tưởng dự đoán khung hình tương lai nhưng giảm chi phí để có thể kiểm chứng trong phạm vi tài nguyên sinh viên. Mô hình sử dụng bốn khung hình quá khứ để dự đoán khung hình kế tiếp; sau đó dùng sai số tái tạo MSE giữa khung hình dự đoán và khung hình thật làm điểm bất thường. Điểm điều chỉnh chính là Spatial Token Bottleneck: mỗi khung hình chỉ được biểu diễn bởi một token không gian trước khi đưa vào Temporal Transformer Encoder nông. Thiết kế này giữ được ý nghĩa học chuyển động theo thời gian nhưng giảm số token cần attention, phù hợp với điều kiện thực nghiệm trên Google Colab. Bài báo trình bày đầy đủ pipeline dữ liệu, kiến trúc, hàm mất mát, cách đánh giá bằng AUC-ROC và phân tích giới hạn thực nghiệm khi không huấn luyện toàn bộ mô hình ở quy mô lớn.

Từ khóa—Phát hiện bất thường, Video Transformer, Spatio-Temporal Attention, Future Frame Prediction, UIT-ADrone, Giao thông thông minh.

I. MỞ ĐẦU

Trong những năm gần đây, các hệ thống giám sát giao thông thông minh ngày càng phụ thuộc vào dữ liệu video. Bên cạnh camera cố định, thiết bị bay không người lái cung cấp góc nhìn rộng, linh hoạt và phù hợp với các khu vực giao thông phức tạp như vòng xoay, ngã tư, đường đông phương tiện hoặc các sự kiện ngoài trời. Tuy nhiên, video từ góc nhìn trên cao cũng tạo ra nhiều thách thức: camera thường xuyên chuyển động, phương tiện có kích thước nhỏ, mật độ

giao thông biến thiên mạnh và các sự kiện bất thường xuất hiện trong thời gian ngắn.

Phát hiện bất thường trong video giao thông có thể được tiếp cận theo hai hướng chính. Hướng có giám sát yêu cầu nhãn chi tiết cho từng loại vi phạm hoặc từng khung hình bất thường. Cách này có thể đạt độ chính xác cao khi dữ liệu nhãn đầy đủ, nhưng khó mở rộng vì các tình huống bất thường trong thực tế rất đa dạng. Hướng học không giám sát chỉ học từ dữ liệu bình thường, sau đó xem các mẫu lệch khỏi quy luật bình thường là bất thường. Hướng này phù hợp hơn với bài toán giao thông vì video bình thường dễ thu thập hơn rất nhiều so với video có sự cố.

Trong bài báo này, nhóm tập trung vào chiến lược dự đoán khung hình tương lai. Mô hình nhận một chuỗi ngắn gồm bốn khung hình quá khứ và dự đoán khung hình kế tiếp. Nếu cảnh giao thông diễn ra bình thường, mô hình có khả năng tái tạo khung hình tiếp theo với sai số nhỏ. Ngược lại, khi xuất hiện va chạm, chuyển động bất thường hoặc hành vi không theo quy luật đã học, sai số tái tạo tăng lên và được dùng làm điểm bất thường.

Transformer là một kiến trúc mạnh cho hiểu video nhờ khả năng mô hình hóa quan hệ xa giữa các vùng ảnh và giữa các khung hình. Dù vậy, attention trên toàn bộ token không gian - thời gian có chi phí lớn, đặc biệt khi xử lý chuỗi video độ phân giải cao. Đối với một bài tập lớn trong phạm vi học phần seminar, việc tái huấn luyện đầy đủ một mô hình Video Transformer quy mô lớn trên toàn bộ dữ liệu drone là không thực tế. Vì vậy, nhóm đề xuất một biến thể nhẹ hơn, đặt trọng tâm vào khả năng giải thích, khả năng kiểm chứng pipeline và khả năng triển khai trên tài nguyên phổ thông.

A. Định vị đóng góp và tính mới

Bài báo này không định vị đóng góp theo hướng phát minh lại toàn bộ nguyên lý Spatio-Temporal Transformer. Thay vào đó, nhóm định vị công việc như một nghiên cứu tái hiện có điều chỉnh: kế thừa ý tưởng học không giám sát bằng dự đoán khung hình tương lai, sau đó thiết kế lại pipeline và kiến trúc theo ràng buộc tính toán thực tế của nhóm sinh viên. Tính mới của bài nằm ở cách đặt bài toán và cách điều

chỉnh kỹ thuật cho điều kiện tài nguyên thấp, cụ thể là giảm số token thời gian, dùng encoder nông và xây dựng quy trình kiểm chứng end-to-end thay vì chỉ mô tả lý thuyết.

Đóng góp chính của bài báo gồm:

- Tái hiện có điều chỉnh hướng Spatio-Temporal Transformer cho phát hiện bất thường giao thông trong video drone theo chiến lược học không giám sát.
- Đề xuất cách nhẹ hóa bằng Spatial Token Bottleneck để giảm số token đưa vào Temporal Transformer Encoder: mỗi khung hình chỉ giữ một token đại diện cho đặc trưng không gian.
- Xây dựng pipeline đầy đủ gồm đọc chuỗi frame, mã hóa không gian, mã hóa thời gian, tái tạo khung hình tương lai, tính MSE anomaly score và chuẩn bị luồng đánh giá bằng AUC-ROC.
- Phân tích tính khả thi của mô hình trong môi trường tài nguyên hạn chế, qua đó chỉ ra vì sao full-scale training không phải mục tiêu phù hợp trong phạm vi seminar.

Phần còn lại của bài báo được tổ chức như sau. Phần II trình bày các nghiên cứu liên quan. Phần III mô tả phương pháp đề xuất. Phần IV trình bày thiết lập thực nghiệm và phân tích khả thi. Phần V đưa ra kết luận và hướng phát triển.

II. NGHIÊN CỨU LIÊN QUAN

A. Phát hiện bất thường trong video

Phát hiện bất thường trong video là bài toán xác định các khung hình hoặc đoạn video có hành vi khác biệt so với quy luật thông thường. Trong giao thông, bất thường có thể là va chạm, xe đi sai làn, phương tiện dừng đột ngột, người đi bộ băng qua vùng nguy hiểm hoặc chuyển động không phù hợp với luồng giao thông. Điểm khó của bài toán là sự kiện bất thường thường hiếm, ngắn và khó định nghĩa đầy đủ bằng một danh sách nhãn cố định.

Các phương pháp truyền thống thường dựa trên đặc trưng thủ công, optical flow, mô hình nền hoặc quỹ đạo đối tượng. Những phương pháp này có ưu điểm là dễ giải thích và ít tổn tài nguyên, nhưng kém ổn định khi camera chuyển động hoặc cảnh giao thông quá đông. Các phương pháp học sâu cải thiện khả năng biểu diễn bằng CNN, LSTM, AutoEncoder hoặc GAN, tuy nhiên nhiều mô hình vẫn gặp khó khăn khi cần học quan hệ thời gian dài giữa các khung hình.

B. Dự đoán khung hình tương lai

Future Frame Prediction là một hướng tiếp cận phổ biến cho phát hiện bất thường không giám sát [8]. Thay vì học trực tiếp nhãn bất thường, mô hình học cách dự đoán khung hình tiếp theo từ các khung hình bình thường trong quá khứ. Gọi $X_{t-4:t-1}$ là chuỗi đầu vào và X_t là khung hình thật tại thời điểm t , mô hình sinh $\hat{X}_t$ và tính điểm bất thường:

$$s_t = \frac{1}{CHW} \|X_t - \hat{X}_t\|_2^2. \quad (1)$$

Khi s_t lớn, khung hình được xem là có khả năng bất thường cao. Ưu điểm của hướng này là không cần nhãn bất thường trong huấn luyện. Hạn chế là sai số tái tạo có thể bị ảnh

hưởng bởi rung camera, thay đổi ánh sáng hoặc chuyển động nền.

C. Video Transformer và Spatio-Temporal Attention

TimeSformer [1], ViViT [2] và Video Swin Transformer [9] cho thấy Transformer có khả năng học biểu diễn video mạnh nhờ cơ chế attention. Với video, attention có thể được áp dụng theo không gian, theo thời gian hoặc kết hợp cả hai. Attention toàn phần trên mọi patch token cho khả năng biểu diễn cao nhưng chi phí tính toán tăng nhanh theo số frame và số patch.

Một hướng tối ưu là tách mã hóa không gian và thời gian. Spatial Encoder trích xuất đặc trưng từng frame, sau đó Temporal Encoder học quan hệ giữa các frame. Cách tách này phù hợp với bài toán giao thông drone vì cho phép giảm số token xử lý ở nhánh thời gian mà vẫn giữ thông tin chuyển động quan trọng.

D. Bộ dữ liệu video drone giao thông

UIT-ADrone [11] là bộ dữ liệu video giao thông từ thiết bị bay không người lái, được xây dựng cho bài toán phát hiện bất thường trong video trên không. Bộ dữ liệu chứa nhiều cảnh giao thông thực tế tại đô thị, có nhãn bất thường ở mức khung hình cho tập kiểm tra. Đây là bộ dữ liệu phù hợp để đánh giá các phương pháp phát hiện bất thường không giám sát vì mô hình có thể huấn luyện trên dữ liệu bình thường và đánh giá bằng AUC-ROC trên nhãn frame-level.

E. Vị trí của phương pháp trong bài báo

Phương pháp của nhóm kế thừa tinh thần của các nghiên cứu dùng Transformer cho phát hiện bất thường trong video [3], [10], [12], nhưng tập trung vào bài toán triển khai trong điều kiện tính toán hạn chế. Thay vì mở rộng mô hình theo hướng lớn hơn, TrafficVision-Transformer giảm số token thời gian bằng Spatial Token Bottleneck và dùng Temporal Transformer Encoder nông. Do đó, đóng góp không nằm ở việc tuyên bố đạt hiệu năng tốt hơn các công trình quy mô lớn, mà nằm ở việc chuyển một hướng nghiên cứu nặng về tính toán thành một prototype có thể phân tích, chạy kiểm chứng từng phần và mở rộng dần khi có tài nguyên tốt hơn.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Tổng quan kiến trúc

TrafficVision-Transformer được thiết kế như một biến thể nhẹ của hướng Spatio-Temporal Transformer cho bài toán phát hiện bất thường ở mức khung hình. Đầu vào của mô hình là bốn khung hình liên tiếp $\{X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}\}$ và đầu ra là khung hình dự đoán $\hat{X}_t$. Sau đó, sai số giữa $\hat{X}_t$ và khung hình thật X_t được dùng làm điểm bất thường.

Pipeline gồm bốn khối chính:

- **Data Loader:** tạo mẫu gồm năm frame liên tiếp, chuẩn hóa ảnh về miền $[-1, 1]$ và sinh hai nhánh độ phân giải.
- **Spatial Transformer Encoder:** trích xuất token không gian đại diện cho từng frame.
- **Temporal Transformer Encoder:** học quan hệ chuyển động giữa các token frame.

- **Decoder:** tái tạo khung hình tương lai ở độ phân giải 256×256 .

Luồng xử lý tổng quát được mô tả bởi:

$$X_{t-4:t-1} \rightarrow STE \rightarrow Z \rightarrow TTE \rightarrow h_t \rightarrow Decoder \rightarrow \hat{X}_t. \quad (2)$$

B. Tiền xử lý chuỗi frame

Với mỗi video, các frame được sắp xếp theo thứ tự thời gian. Một mẫu huấn luyện gồm $T+1$ frame, trong đó $T = 4$ frame đầu dùng làm đầu vào và frame cuối làm mục tiêu dự đoán. Trong project, mỗi frame được tạo ở hai kích thước:

- Nhánh *standard*: dùng cho encoder, có kích thước cấu hình như 224, 256 hoặc 384.
- Nhánh *256*: dùng làm mục tiêu tái tạo cho hàm mất mát MSE.

Thiết kế hai nhánh này giúp encoder vẫn có thể khai thác ảnh đầu vào độ phân giải cao hơn, trong khi decoder chỉ cần tái tạo ảnh 256×256 để giảm bộ nhớ và thời gian huấn luyện.

C. Spatial Token Bottleneck: điểm điều chỉnh chính

Nếu đưa toàn bộ patch token của mỗi frame vào Transformer thời gian, số token sẽ tăng nhanh theo độ phân giải ảnh. Ví dụ với ảnh 384×384 và patch size 32, mỗi frame có 144 patch token. Với bốn frame, attention thời gian trên toàn bộ patch token sẽ rất tốn tài nguyên.

Để giảm chi phí, nhóm sử dụng Spatial Token Bottleneck. Đây là điểm điều chỉnh chính so với cách xử lý video Transformer nặng hơn: thay vì để Temporal Encoder nhìn thấy toàn bộ patch token, mỗi frame X_i đi qua Spatial Transformer Encoder và chỉ giữ một token đại diện:

$$z_i = STE(X_i), \quad z_i \in \mathbb{R}^d. \quad (3)$$

Chuỗi bốn frame được biểu diễn thành ma trận:

$$Z = [z_{t-4}, z_{t-3}, z_{t-2}, z_{t-1}] \in \mathbb{R}^{T \times d}. \quad (4)$$

Nhờ đó, Temporal Encoder chỉ xử lý số token tỉ lệ với số frame, không còn tỉ lệ với số patch trong ảnh. Với phạm vi seminar, lựa chọn này là thỏa hiệp hợp lý: mô hình có thể mất một phần chi tiết không gian nhỏ, nhưng đổi lại pipeline có thể chạy, debug và phân tích trên tài nguyên phổ thông.

D. Temporal Transformer Encoder

Để học quan hệ thời gian, một token [CLS] học được được thêm vào đầu chuỗi:

$$E = [z_{cls}, z_{t-4}, z_{t-3}, z_{t-2}, z_{t-1}]. \quad (5)$$

Sau đó, chuỗi này được đưa qua Temporal Transformer Encoder:

$$H = TTE(E). \quad (6)$$

Vector tại vị trí [CLS] sau khi mã hóa, ký hiệu $h_t = H_0$, được dùng như biểu diễn tổng hợp của toàn bộ đoạn video ngắn. TTE trong mô hình được giữ nguyên để phù hợp tài nguyên tính toán và giảm nguy cơ huấn luyện quá lâu.

E. Decoder và hàm mất mát

Decoder nhận vector h_t và tái tạo khung hình tương lai $\hat{X}_t$. Đầu tiên, h_t được ánh xạ tuyến tính thành tensor đặc trưng, sau đó đi qua các lớp convolution và transposed convolution để sinh ảnh RGB 256×256 .

Hàm mất mát huấn luyện là MSE reconstruction:

$$\mathcal{L}_{rec} = \frac{1}{N} \sum_{t=1}^N \|X_t^{256} - \hat{X}_t\|_2^2. \quad (7)$$

Trong đó X_t^{256} là khung hình thật đã resize về 256×256 . Mô hình chỉ cần tối ưu khả năng tái tạo dữ liệu bình thường.

F. Điểm bất thường và quyết định

Ở giai đoạn suy luận, với mỗi thời điểm t , điểm bất thường được tính như sau:

$$s_t = MSE(X_t^{256}, \hat{X}_t). \quad (8)$$

Điểm số càng cao thì khả năng bất thường càng lớn. Để so sánh giữa các video, có thể chuẩn hóa điểm số về $[0, 1]$:

$$\tilde{s}_t = \frac{s_t - \min(s)}{\max(s) - \min(s) + \epsilon}. \quad (9)$$

Trong cấu hình đơn giản, ngưỡng phát hiện được xác định theo trung bình và độ lệch chuẩn:

$$\tau = \mu_s + \sigma_s. \quad (10)$$

Khung hình được dự đoán là bất thường nếu $s_t > \tau$.

G. Thuật toán

H. Thuật toán huấn luyện

Quy trình huấn luyện có thể tóm tắt như sau:

- 1) Khởi tạo Spatial Transformer Encoder, Temporal Transformer Encoder và Decoder.
- 2) Với mỗi batch, lấy chuỗi $X_{t-4:t}$ gồm năm frame liên tiếp.
- 3) Đưa bốn frame đầu qua STE để thu được chuỗi token Z .
- 4) Đưa Z qua TTE để thu được biểu diễn tổng hợp h_t .
- 5) Decoder sinh khung hình dự đoán $\hat{X}_t$.
- 6) Tính $\mathcal{L}_{rec} = MSE(X_t^{256}, \hat{X}_t)$ và cập nhật tham số bằng lan truyền ngược.

IV. THỰC NGHIỆM ĐÁNH GIÁ

A. Môi trường và dữ liệu

Thực nghiệm được thiết kế cho bộ dữ liệu UIT-ADrone [11]. Tập huấn luyện chỉ sử dụng các frame bình thường. Tập kiểm tra dùng nhân ở mức khung hình để tính AUC-ROC. Do giới hạn tài nguyên, nhóm ưu tiên kiểm chứng pipeline và phân tích khả thi thay vì huấn luyện full-scale trên toàn bộ dữ liệu trong thời gian dài.

Mã nguồn được tổ chức thành các thư mục chính:

- **data**: xử lý dữ liệu và tạo chuỗi frame.
- **models**: cài đặt các biến thể Vision Transformer.
- **configs**: khai báo tham số huấn luyện và kiến trúc.
- **scripts**: train, inference và lưu checkpoint.
- **results**: tính AUC và trực quan hóa ROC.

B. Cấu hình thực nghiệm

Bảng I trình bày cấu hình chính được sử dụng trong project.

TABLE I
CẤU HÌNH THỰC NGHIỆM CHÍNH

Thành phần	Giá trị
Số frame đầu vào	4
Số frame dự đoán	1
Kích thước ảnh encoder	224 / 256 / 384
Kích thước ảnh target	256 × 256
Kiến trúc không gian	ViT-base patch32
Temporal Encoder	Transformer nông
Batch size mặc định	8
Optimizer	SGD momentum 0.9
Learning rate	10^{-4}
Loss	MSE reconstruction
Metric	AUC-ROC frame-level

C. Quy trình đánh giá

Sau khi huấn luyện, mô hình chạy inference trên từng video kiểm tra. Với mỗi sample, mô hình sinh điểm bất thường s_t . Các điểm số này được lưu dưới dạng file .npy. Sau đó, script tính AUC so sánh chuỗi điểm dự đoán với nhãn frame-level tương ứng. AUC-ROC được chọn vì không phụ thuộc vào một ngưỡng cố định và phù hợp với bài toán dữ liệu mất cân bằng.

Quy trình đánh giá gồm:

- 1) Tải checkpoint tốt nhất của mô hình.
- 2) Duyệt từng scene trong tập kiểm tra.
- 3) Tính MSE reconstruction cho từng frame dự đoán.
- 4) Lưu chuỗi anomaly score.
- 5) Tính AUC-ROC bằng nhãn `test_frame_mask`.

D. Baseline so sánh

Project giữ thêm một baseline CA để so sánh về mặt kiến trúc. Baseline này cũng dùng hướng dự đoán khung hình tương lai, nhưng cách kết hợp đặc trưng không gian - thời gian khác với TrafficVision-Transformer. Mục tiêu của baseline là cung cấp điểm đối chiếu khi có đủ tài nguyên huấn luyện, không phải khẳng định kết quả vượt trội khi chưa chạy đầy đủ.

E. Phân tích chi phí tính toán

Huấn luyện mô hình video trên UIT-ADrone tốn nhiều thời gian vì mỗi sample gồm nhiều frame và mỗi frame phải đi qua Vision Transformer. Khi dùng ảnh 384×384 , batch size 8 và hàng chục nghìn bước huấn luyện, Google Colab free hoặc GPU T4 thường không đủ thuận lợi để tái lập đầy đủ kết quả công bố. Ngoài ra, nếu frame được đọc trực tiếp từ Google Drive, tốc độ I/O có thể trở thành nút nghẽn lớn hơn cả tốc độ GPU.

Thiết kế Spatial Token Bottleneck giúp giảm chi phí ở Temporal Encoder. Thay vì xử lý mọi patch token của bốn frame, mô hình chỉ xử lý bốn token đại diện cộng với một token [CLS]. Nhờ vậy, nhánh thời gian nhẹ hơn và có thể kiểm chứng forward pass, loss, checkpoint và inference trong phạm vi bài tập lớn.

F. Kết quả kiểm chứng pipeline

Do chưa huấn luyện full-scale đến khi hội tụ, bài báo không trình bày AUC như một kết quả so sánh cuối cùng. Đây là lựa chọn có chủ đích để tránh báo cáo một con số thiếu ổn định. Thay vào đó, nhóm kiểm chứng các điểm sau:

- Data Loader tạo đúng sample gồm bốn frame đầu vào và một frame mục tiêu.
- Mô hình nhận tensor dạng (B, T, C, H, W) và sinh ảnh tái tạo dạng $(B, 3, 256, 256)$.
- Hàm mất mát MSE được tính giữa frame target và frame dự đoán.
- Checkpoint có thể lưu, resume và dùng cho inference.
- Chuỗi anomaly score có thể lưu thành .npy và đưa vào script tính AUC.

Vì vậy, kết quả của bài được hiểu là kết quả prototype: chứng minh pipeline và biến thể kiến trúc hoạt động đúng về mặt kỹ thuật. Khi có GPU mạnh hơn và thời gian huấn luyện dài hơn, cùng pipeline này có thể được dùng để báo cáo AUC-ROC đầy đủ trên toàn bộ tập kiểm tra.

G. Thảo luận

Điểm mạnh của phương pháp là cách tiếp cận đơn giản, dễ giải thích và phù hợp với học không giám sát. MSE reconstruction trực quan: mô hình càng khó dự đoán frame tương lai thì khả năng bất thường càng cao. Tuy nhiên, phương pháp cũng có hạn chế. Sai số MSE toàn ảnh có thể tăng do thay đổi ánh sáng, rung camera hoặc chuyển động nền, không chỉ do sự kiện bất thường. Ngoài ra, việc dùng một token đại diện cho mỗi frame có thể làm mất chi tiết của các phương tiện rất nhỏ.

Các cải tiến tiềm năng gồm: dùng pretrained ViT để giảm thời gian hội tụ, fine-tuning một phần encoder thay vì huấn luyện toàn bộ, thêm optical flow để nhấn mạnh chuyển động, hoặc dùng score smoothing theo thời gian để giảm nhiễu trên từng frame đơn lẻ.

V. KẾT LUẬN

Bài báo đã trình bày TrafficVision-Transformer, một nghiên cứu tái hiện có điều chỉnh từ hướng Spatio-Temporal Transformer cho phát hiện bất thường giao thông trong video drone. Phương pháp sử dụng chiến lược học không giám sát bằng dự đoán khung hình tương lai: mô hình học quy luật chuyển động bình thường từ bốn frame quá khứ và dùng sai số tái tạo frame kế tiếp làm điểm bất thường.

Đóng góp chính của nhóm là thiết kế lại pipeline theo hướng gọn và có khả năng kiểm chứng trong điều kiện tài nguyên hạn chế. Spatial Token Bottleneck giúp giảm số token đưa vào Temporal Transformer Encoder, từ đó giảm chi phí tính toán nhưng vẫn giữ thông tin chuyển động theo thời gian. Do đó, tính mới của bài nằm ở hướng thích nghi mô hình cho bối cảnh tài nguyên thấp, không nằm ở việc tuyên bố một mô hình SOTA hoàn toàn mới. Bài báo cũng phân tích rõ giới hạn của việc huấn luyện full-scale trên Google Colab và đề xuất cách đánh giá trung thực bằng pipeline inference, anomaly score và AUC-ROC khi có checkpoint đủ tốt.

Trong tương lai, nhóm sẽ tập trung vào ba hướng phát triển. Thứ nhất, sử dụng trọng số pretrained cho Spatial Transformer Encoder để rút ngắn thời gian hội tụ. Thứ hai, bổ sung cơ chế chọn vùng chuyển động hoặc vùng phương tiện để giảm ảnh hưởng của nền. Thứ ba, hoàn thiện thực nghiệm trên toàn bộ UIT-ADrone, so sánh với baseline CA và báo cáo đầy đủ AUC-ROC, EER, tốc độ suy luận và phân tích lỗi.

TÀI LIỆU THAM KHẢO

- [1] Bertasius, G., Wang, H., and Torresani, L. (2021). Is Space-Time Attention All You Need for Video Understanding?. *Proceedings of the International Conference on Machine Learning (ICML)*. [Online]. Available: <https://arxiv.org/abs/2102.05095>.
- [2] Arnab, A., Dehghani, M., Peemen, G., Schmid, C., Zisserman, A., and Houlsby, M. (2021). ViViT: A Video Vision Transformer. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [Online]. Available: <https://arxiv.org/abs/2103.15691>.
- [3] Yuan, H., Cai, Z., Zhou, H., Wang, Y., and Chen, X. (2021). TransAnomaly: Video Anomaly Detection Using Video Vision Transformer. *IEEE Access*. [Online]. Available: <https://ieeexplore.ieee.org/document/9525368>.
- [4] Noghre, G. A., Pazho, A. D., and Tabkhi, H. (2024). Human-Centric Video Anomaly Detection Through Spatio-Temporal Pose Tokenization and Transformer. *arXiv preprint*. [Online]. Available: <https://arxiv.org/abs/2408.15185>.
- [5] Gao, A., and Liu, J. (2025). STEAD: Spatio-Temporal Efficient Anomaly Detection for Time and Compute Sensitive Applications. *arXiv preprint*. [Online]. Available: <https://arxiv.org/abs/2503.07942>.
- [6] Ahn, S., and Ko, K. (2022). Video Vision Transformer for Traffic Violation Detection. *IEEE Access*. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11020668>.
- [7] Park, H., Noh, J., and Ham, B. (2020). Learning Memory-guided Normality for Anomaly Detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [8] Liu, W., Luo, W., Lian, D., and Gao, S. (2018). Future Frame Prediction for Anomaly Detection – A New Baseline. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [9] Liu, Z., et al. (2022). Video Swin Transformer. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/9740525>.
- [10] Wu, J., et al. (2022). Video Anomaly Detection via Transformer with Spatio-Temporal Context. *Computer Vision – ECCV 2022 Workshops*. [Online]. Available: https://link.springer.com/chapter/10.1007/978-3-031-19818-2_38.
- [11] Tran, T. M., Vu, T. N., Nguyen, T. V., and Nguyen, K. (2023). UIT-ADrone: A Novel Drone Dataset for Traffic Anomaly Detection. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 16, pp. 5590–5601.
- [12] Tran, T. M., Bui, D. C., Nguyen, T. V., and Nguyen, K. (2024). Transformer-based Spatio-Temporal Unsupervised Traffic Anomaly Detection in Aerial Videos. *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, pp. 8292–8309.

PHỤ LỤC

1. Cấu trúc mã nguồn

Project được tổ chức theo hướng tách rõ dữ liệu, mô hình, huấn luyện và đánh giá:

- `configs/train_config.py`: khai báo tham số thực nghiệm như batch size, learning rate, image size, số epoch và checkpoint.
- `data/dataset.py`: đọc frame, resize ảnh, chuẩn hóa và tạo sample gồm năm frame liên tiếp.
- `models/vit_ste_tte.py`: cài đặt TrafficVision-Transformer với Spatial Transformer Encoder, Temporal Transformer Encoder và Decoder.
- `models/vit_baseline_ca.py`: baseline dùng để đối chiếu kiến trúc.
- `scripts/train_ste_tte.py`: train, validation, resume checkpoint và inference cho mô hình đề xuất.
- `compute_auc.py`: tính AUC-ROC từ các file anomaly score và nhãn frame-level.

2. Lệnh huấn luyện tham khảo

```
python scripts/train_ste_tte.py \
    --train 1 \
    --epochs 5 \
    --batch-size 8 \
    --lr 1e-4 \
    --model-arch b16 \
    --image-size 384 \
    --data-dir ../../UIT-ADrone
```

Trong điều kiện Colab giới hạn, có thể giảm chi phí bằng cách dùng `-image-size 224`, giảm `-batch-size`, giảm số epoch hoặc chỉ chạy trên một phần nhỏ dữ liệu để kiểm chứng pipeline.

3. Lệnh inference và tính AUC

```
python scripts/train_ste_tte.py \
    --train 0 \
    --data-dir ../../UIT-ADrone
```

```
python compute_auc.py \
    --scores-dir experiments_andt_ADrone_STE_TTE/ \
    --labels-dir ../../UIT-ADrone/test/test_frame_mask/ \
    --plot \
    --save-plot results/roc_ste_tte.png
```

4. Phân công công việc

Thành viên	Nhiệm vụ	Sản phẩm
Đặng Quang Minh	Tiền xử lý dữ liệu, kiểm tra DataLoader, viết phần đánh giá và AUC	Module dữ liệu và AUC
Vũ Hoàng Diệu Linh	Cài đặt và phân tích mô hình STE-TTE nhẹ, kiểm tra forward pass và checkpoint	Module STE-TTE và train script
Lê Hồng Phương Chi	Baseline, tổng hợp kết quả, viết báo cáo và slide	Baseline và phần kết quả

5. Ghi chú thực nghiệm

Do mô hình video Transformer có chi phí lớn, kết quả cuối cùng cần được hiểu theo hai mức:

- **Mức kiểm chứng pipeline**: đảm bảo dữ liệu, mô hình, loss, checkpoint và inference hoạt động đúng.
- **Mức thực nghiệm đầy đủ**: cần GPU mạnh hơn, dữ liệu được lưu cục bộ nhanh hơn và thời gian train dài hơn để báo cáo AUC ổn định.