

Spatio-Temporal Attention (Chú ý không - thời gian) trong Video Transformer ứng dụng cho nhận diện hành vi vi phạm giao thông trong hệ thống camera an ninh.

Vũ Hoàng Diệu Linh, Đặng Quang Minh, Lê Hồng Phương Chi
Viện Trí tuệ nhân tạo
Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội
144 Xuân Thủy, Cầu Giấy, Hà Nội, Việt Nam
{24022387, 24022397, 24022270}@vnu.edu.vn

Tóm tắt—Bài nghiên cứu này hướng tới việc khai thác các phương pháp hiệu quả để nhận diện hành vi vi phạm giao thông thông qua hệ thống camera an ninh. Trong lĩnh vực thị giác máy tính, việc nhận diện hành vi trong video đòi hỏi khả năng phân tích và dự đoán dựa trên sự tương tác phức tạp của các đối tượng trong cả không gian và thời gian. Trong bài báo này, việc xử lý khối lượng tính toán lớn từ dữ liệu video được giải quyết thông qua việc ứng dụng cơ chế Chú ý không - thời gian (Spatio-Temporal Attention) trong kiến trúc Video Transformer; cho phép mô hình tập trung vào các đặc trưng hình ảnh và chuỗi chuyển động quan trọng nhất của phương tiện. Bài báo cũng nhằm mục đích đánh giá hiệu năng và độ chính xác của mô hình đề xuất so với các thuật toán truyền thống khác trong việc giải quyết cùng một bài toán. Nghiên cứu này không chỉ đóng vai trò như một giải pháp thay thế tối ưu cho việc giám sát thủ công phức tạp mà còn đặc biệt hữu ích cho các hệ thống dữ liệu lớn (big data) đòi hỏi tốc độ xử lý nhanh và tự động hóa cao trong giao thông thông minh.

Từ khóa—Chú ý không - thời gian, Video Transformer, Nhận diện hành vi, Vi phạm giao thông, Camera an ninh, Giao thông thông minh.

I. MỞ ĐẦU

Trong bối cảnh đô thị hóa nhanh chóng, việc quản lý an toàn giao thông trở thành một thách thức lớn đối với các đô thị thông minh. Hệ thống camera an ninh được lắp đặt dày đặc tạo ra một lượng dữ liệu video khổng lồ, vượt quá khả năng giám sát thủ công của con người. Do đó, nhu cầu về các giải pháp tự động nhận diện hành vi vi phạm giao thông với độ chính xác và tốc độ xử lý cao đã trở nên cấp thiết hơn bao giờ hết.

Nhận diện hành vi trong video là một bài toán khó trong thị giác máy tính do đòi hỏi sự kết hợp chặt chẽ giữa đặc trưng không gian và động lực học thời gian. Trước đây, các mạng tích chập (CNN) thường được sử

dụng nhưng còn hạn chế trong việc nắm bắt các mối liên hệ xa giữa các khung hình. Sự xuất hiện của kiến trúc Transformer, tiêu biểu là các nghiên cứu về cơ chế chú ý không - thời gian [1] và các biến thể mô hình video [2], [9], đã mở ra hướng đi mới đầy triển vọng. Các kiến trúc này cho phép mô hình tập trung vào những vùng ảnh và phân đoạn thời gian quan trọng nhất, từ đó cải thiện đáng kể khả năng hiểu nội dung video.

Tuy nhiên, việc áp dụng Transformer vào nhận diện vi phạm giao thông thực tế vẫn đối mặt với hai thách thức lớn: (1) Khối lượng tính toán cực lớn từ dữ liệu video độ phân giải cao và (2) Sự phức tạp của các hành vi vi phạm trong môi trường giao thông hỗn hợp. Mặc dù đã có nhiều nghiên cứu về phát hiện bất thường trong video [3], [4], [10] cũng như các kiến trúc tối ưu hóa hiệu năng và chú ý đặc thù [5], [7], [8], việc xây dựng một hệ thống chuyên biệt cho giám sát giao thông [6] vẫn cần được nghiên cứu sâu hơn để cân bằng giữa độ chính xác và khả năng triển khai thực tế.

Trong bài báo này, chúng tôi đề xuất ứng dụng cơ chế Chú ý không - thời gian (Spatio-Temporal Attention) trong Video Transformer để nhận diện các hành vi vi phạm giao thông từ camera an ninh. Nghiên cứu tập trung vào việc khai thác các đặc trưng chuyển động then chốt của phương tiện, đồng thời đánh giá hiệu năng của mô hình so với các phương pháp truyền thống nhằm hướng tới một giải pháp giám sát tự động hóa và hiệu quả.

II. NGHIÊN CỨU LIÊN QUAN

III. PHƯƠNG PHÁP ĐỀ XUẤT

IV. THỰC NGHIỆM ĐÁNH GIÁ

V. KẾT LUẬN

TÀI LIỆU THAM KHẢO

- [1] Bertasius, G., Wang, H., and Torresani, L. (2021). Is Space-Time Attention All You Need for Video Understanding?. *Proceedings*

- of the International Conference on Machine Learning (ICML). [Online]. Available: <https://arxiv.org/abs/2102.05095>.
- [2] Arnab, A., Dehghani, M., Peemen, G., Schmid, C., Zisserman, A., and Hounsby, M. (2021). ViViT: A Video Vision Transformer. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [Online]. Available: <https://arxiv.org/abs/2103.15691>.
 - [3] Yuan, H., Cai, Z., Zhou, H., Wang, Y., and Chen, X. (2021). TransAnomaly: Video Anomaly Detection Using Video Vision Transformer. *IEEE Access*. [Online]. Available: <https://ieeexplore.ieee.org/document/9525368>.
 - [4] Noghre, G. A., Pazho, A. D., and Tabkhi, H. (2024). Human-Centric Video Anomaly Detection Through Spatio-Temporal Pose Tokenization and Transformer. *arXiv preprint*. [Online]. Available: <https://arxiv.org/abs/2408.15185>.
 - [5] Gao, A., and Liu, J. (2025). STEAD: Spatio-Temporal Efficient Anomaly Detection for Time and Compute Sensitive Applications. *arXiv preprint*. [Online]. Available: <https://arxiv.org/abs/2503.07942>.
 - [6] Ahn, S., and Ko, K. (2022). Video Vision Transformer for Traffic Violation Detection. *IEEE Access*. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11020668>.
 - [7] Ahn, J., et al. (2023). STAR-Transformer: A Spatio-Temporal Cross Attention Transformer for Human Action Recognition. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. [Online]. Available: https://openaccess.thecvf.com/content/WACV2023/html/Ahn_STAR-Transformer_A_Spatio-Temporal_Cross_Attention_Transformer_for_Human_Action_Recognition_WACV_2023_paper.html.
 - [8] Diba, A., et al. (2023). Spatio-Temporal Convolution-Attention Video Network. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2023W/NIVT/html/Diba_Spatio-Temporal_Convolution-Attention_Video_Network_ICCVW_2023_paper.html.
 - [9] Liu, Z., et al. (2022). Video Swin Transformer. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/9740525>.
 - [10] Wu, J., et al. (2022). Video Anomaly Detection via Transformer with Spatio-Temporal Context. *Computer Vision – ECCV 2022 Workshops*. [Online]. Available: https://link.springer.com/chapter/10.1007/978-3-031-19818-2_38.

PHỤ LỤC

1. Dự kiến kế hoạch thực hiện

Dự án được triển khai trong vòng 11 tuần với 4 giai đoạn chính:

- **Giai đoạn 1:** Hoàn thiện cơ sở dữ liệu và môi trường (đến 17/04).
- **Giai đoạn 2:** Phát triển và huấn luyện mô hình cốt lõi (đến 10/05).
- **Giai đoạn 3:** Đánh giá hiệu năng và xây dựng giao diện demo (đến 24/05).
- **Giai đoạn 4:** Hoàn thiện hồ sơ nghiệm thu dự án (31/05).

2. Phân công công việc

Dưới đây là chi tiết phân công công việc dựa trên kế hoạch thực hiện dự án:

Giai đoạn	Nhiệm vụ cụ thể	Phụ trách	Thời hạn
1. Khởi tạo	Chốt đề tài	Minh, Chi, Linh	16/03 - 22/03
	Nghiên cứu lý thuyết & Chốt scope	Minh, Chi, Linh	23/03 - 29/03
	Thu thập data & Setup môi trường	Minh, Chi	30/03 - 10/04
	Tiền xử lý (Cắt frame) & Gán nhãn	Minh, Chi, Linh	10/04 - 17/04
	Viết Dataloader cho Video	Chi	10/04 - 17/04
2. Phát triển	Code baseline (3D-CNN)	Minh	10/04 - 17/04
	Code kiến trúc Video Transformer	Linh	10/04 - 19/04
	Tích hợp, Debug & Chạy Training	Linh, Chi	20/04 - 03/05
	Hyperparameter Tuning & Augment	Linh, Chi	04/05 - 10/05
3. Đánh giá	Đánh giá metrics & Error analysis	Minh, Chi, Linh	11/05 - 17/05
	Tối ưu hóa tốc độ (FPS)	Minh, Linh	11/05 - 17/05
	Viết API nhận luồng video	Chi	18/05 - 24/05
	Code giao diện Demo (UI)	Minh	18/05 - 24/05
4. Tổng kết	Viết báo cáo & Slide, Quay video	Minh, Chi, Linh	25/05 - 31/05